МИНОБРНАУКИ РОССИИ САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ ЭЛЕКТРОТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ «ЛЭТИ» ИМ. В.И. УЛЬЯНОВА (ЛЕНИНА) Кафедра МО ЭВМ

ОТЧЕТ

по лабораторной работе №5 по дисциплине «Построение и анализ алгоритмов»

Тема: Алгоритм Ахо-Корасик

Студент гр. 8382	 Ершов М.И
Преподаватель	Фирсов М.А

Санкт-Петербург 2020

Цель работы

Изучить работу алгоритма Ахо-Корасик для решения задач точного поиска набора образцов и поиска образца с джокером (символом, совпадающим с любым из алфавита).

Задание 1

Разработайте программу, решающую задачу точного поиска набора образцов.

Вход:

Первая строка содержит текст (T, $1 \le |T| \le 100000$)

Вторая - число ($1 \le n \le 3000$), каждая следующая из строк содержит шаблон из набора = $\{p_1, \ldots, p_n\}$ $1 \le |p_i| \le 75$

Все строки содержат символы из алфавита {A,C,G,T,N}

Выход:

Все вхождения образцов из Р в Т.

Каждое вхождение образца в текст представить в виде двух чисел -i р, где i - позиция в тексте (нумерация начинается с 1), с которой начинается вхождение образца с номером р (нумерация образцов начинается с 1).

Строки выхода должны быть отсортированы по возрастанию, сначала номера позиции, затем номера шаблона.

Sample Input:

NTAG

3

TAGT

TAG

T

Sample Output:

22

23

Задание 2

Используя реализацию точного множественного поиска, решите задачу точного поиска для одного образца с джокером.

В шаблоне встречается специальный символ, именуемый джокером (wild card), который "совпадает" с любым символом. По заданному содержащему шаблоны образцу Р необходимо найти все вхождения Р в текст Т.

Например, образец а??с? с джокером? встречается дважды в тексте.

Символ джокер не входит в алфавит, символы которого используются в Т. Каждый джокер соответствует одному символу, а не подстроке неопределённой длины. В шаблон входит хотя бы один символ не джокер, т.е. шаблоны вида ??? недопустимы.

Все строки содержат символы из алфавита {A,C,G,T,N}

Вход:

Текст (T, $1 \le |T| \le 100000$)

Шаблон ($P, 1 \le |P| \le 40$)

Символ джокера

Выход:

Строки с номерами позиций вхождений шаблона (каждая строка содержит только один номер).

Номера должны выводиться в порядке возрастания.

Sample Input:

ACTANCA

A\$\$A\$

\$

Sample Output:

1

Индивидуализация

Вариант 4

Реализовать режим поиска, при котором все найденные образцы не пересекаются в строке поиска (т.е. некоторые вхождения не будут найдены; решение задачи неоднозначно).

Описание Бора

Бор — структура данных для хранения набора строк, представляющая из себя дерево с символами на рёбрах. Строки получаются последовательной записью символов между корнем дерева и терминальной вершиной.

Из такой структуры данных возможно построить автомат, для этого необходимо добавить ссылки на максимальные суффиксы строк.

Описание алгоритма задания 1

В программе используется алгоритм Ахо-Корасик.

Для всех строк шаблонов строится автомат по бору. Далее, для каждого символа текста выполняется поиск по автомату.

По возможности переходим либо в потомка, если для текущей вершины он существует, либо по суффиксной ссылке. После перехода выполняется проверка на то, является ли вершина и всевозможные её суффиксы — терминальными. Если да, то возвращаем все такие найденные номера паттернов. Если символа в автомате не оказалось, то текущая вершина принимает значение корня — вхождение не найдено.

Для того, чтобы найти не пересекающиеся шаблоны в тексте (индивидуализация), был удалён переход по суффиксам и после каждой найденной терминальной вершины - значение текущей позиции в автомате становилось равным корню.

Описание алгоритма задания 2

Здесь шаблонами являются подстроки маски, разделенные символами джокера, обозначим множество таких подстрок как $\{R_1, \ldots, R_n\}$. По таким подстрокам также строится автомат по бору. После этого для каждого символа текста выполняется поиск в нём. Появления подстроки в тексте на позиции означает возможное появление маски на позиции -+1, где - индекс начала подстроки в маске. Далее, с помощью вспомогательного массива для таких позиций увеличиваем его значение на 1. Индексы, по которым хранятся значения равному, являются вхождениями маски в текст.

Сложность алгоритма

Построение бора выполняется за O(m), где m — суммарная длина паттернов (для джокеров — $\sum Q_i$). Для построения суффиксных ссылок используется обход в ширину. Его сложность составляет O(V+E), но т.к. кол-во рёбер линейно зависит от кол-ва вершин, то упрощаем до O(2m) = O(m). Прохождение текста по бору составляет O(n), где n — длина текста. В алгоритме поиска маски, в тексте просматривается промежуточный массив, но его размер равен размеру исходного текста, таким образом на сложность это никак не влияет. Итак, сложность по времени составляет O(m+n).

Сложность по памяти для хранения бора составляет O(m) - каждый символ представляет собой вершину бора, также на каждой позиции текста могут встретиться все шаблоны, что в свою очередь приводит к общей сложности по памяти O(n*k+m).

Описание функций и структур данных

Class TreeNode – структура, для хранения данных на вершину бора.

Поля TreeNode:

char value – символ, по которому был произведён переход;

TreeNode* parent – ссылка на родительскую вершину;

TreeNode* suffixLink – суффиксная ссылка;

unordered_map <char, TreeNode*> children – словарь, ключом которого является символ, по которому можно перейти на потомка;

size_t numOfPattern – порядковый номер паттерна (в задании 1)

vector<pair<size_t, size_t>> substringEntries – вектор, элементами которого является пара: индекс вхождения в маску и длина подстроки (в задания 2)

Методы TreeNode:

TreeNode(char val) — конструктор для заполнения поля : значения по которому перешли;

void insert(const string &str) – метод для вставки строки в бор;

auto find(const char c) – выполняет поиск, по заданному символу, в боре, в случае найденной терминальной вершины, возвращает либо вектор size_t (задание 1), либо вектор пар size_t (задание 2);

void makeAutomaton() – делает из бора автомат, путём добавления суффиксных ссылок;

Class Trie – обёртка над классом TreeNode, состоящая из одного поля и аналогичных методов.

Функции задания 1:

set<pair<size_t, size_t>> AhoCorasick(const string &text, const vector<string> &patterns) — функция, возвращающая множество, состоящее из пары индекса вхождения в текст и номера паттерна, который был найден в нём.

Функции задания 2:

vector <size_t> AhoCorasick(const string &text, const string &mask, const char joker)— функция, возвращающая вектор индексов вхождения маски в текст.

Тестирование

Задание 1

Ввод	Вывод	
ABCASDTEAD	11	
5	4 3	
ABC	7 4	
CAS		
ASD		
TEA		
EAD		
ABCBABCBA	11	
4	4 4	
ABC	7 3	
BC		
CBA		
BAB		
CATNATCAT	1 2	
3	4 3	
AT	7 2	
CAT		
NA		
CCCA	11	
1		
CC		

Тест с подробным промежуточным выводом:

ABABA 1 ABA

Бор сейчас: Вставляем строку: АВА Корень: Бор сейчас: Потомок: А Суффиксная ссылка: Root Родитель: Корень Родитель: Корень Потомок: В Суффиксная ссылка: Root Родитель: А Родитель: АВ Суффиксная ссылка: А Родитель: АВ Родитель: Корень Ищем 'А' из: Корень Суффиксная ссылка: Корень Символ 'А' найден! Ищем 'В' из: А Символ 'В' найден! Родитель: А Ищем 'А' из: АВ Символ 'А' найден! Суффиксная ссылка: Корень Ищем 'В' из: АВА Переходим по суффиксной ссылке: А Родитель: АВ Символ 'В' найден! Суффиксная ссылка: А Символ 'А' найден! Бор сейчас: 3 1

Задание 2:

Ввод	Вывод
ACTANCA	1
A\$\$A	
\$	
CATNATCAT	1
\$AT	4
\$	7

Тест с подробным промежуточным выводом

ABCBABC

B\$B

\$

```
Вставляем строку: В
                         Ищем 'А' из: Корень
Бор сейчас:
                         Символ 'А' не найден!
                         Ищем 'В' из: Корень
                         Символ 'В' найден!
                         Ищем 'С' из: В
Бор сейчас:
                         Переходим по суффиксной ссылке: Корень
                         Символ 'С' не найден!
                         Ищем 'В' из: Корень
                         Символ 'В' найден!
Строим автомат:
                         Ищем 'А' из: В
                         Переходим по суффиксной ссылке: Корень
     Родитель: Корень
                         Символ 'А' не найден!
                         Ищем 'В' из: Корень
Бор сейчас:
                         Символ 'В' найден!
                         Ищем 'С' из: В
                         Переходим по суффиксной ссылке: Корень
     Родитель: Корень
                         Символ 'С' не найден!
                         2
Ищем 'А' из: Корень
```

Вывод

В ходе выполнения лабораторной работы была изучена работа алгоритма Ахо-Корасик. Алгоритм был использован для нахождения вхождений множества строк в тексте, а также для нахождения шаблона с джокером.

Приложение А

Код программы 1

```
#include <iostream>
#include <string>
#include <vector>
#include <set>
#include <queue>
#include <unordered_map>
using namespace std;
class TreeNode {
public:
  explicit TreeNode(char val): value(val) {} // Конструктор ноды
 // Отладочная функция для печати бора
 void printTrie() {
    cout << "Бор сейчас:" << endl;
    queue<TreeNode *> queue;
    queue.push(this);
    while (!queue.empty()) {
      auto curr = queue.front();
      if (!curr->value)
        cout << "Корень:" << endl;
      else
        cout << curr->dbgStr << ':' << endl;</pre>
      if (curr->suffixLink)
        cout << "\tCyффиксная ссылка: " << (curr->suffixLink == this? "Root" : curr->suffixLink->dbgStr) << endl;
      if (curr->parent && curr->parent->value)
        cout << "\tPoдитель: " << curr->parent->dbgStr << endl;
      else if (curr->parent)
        cout << "\tРодитель: Корень" << endl;
      if (!curr->children.empty()) cout << "\tПотомок: ";
      for (auto child: curr->children) {
        cout << child.second->value << ' ';</pre>
        queue.push(child.second);
      }
      queue.pop();
      cout << endl;
    }
    cout << endl;
 }
 // Вставка подстроки в бор
  void insert(const string &str) {
    auto curr = this;
    static size_t countPatterns = 0;
    for (char c : str) { // Идем по строке
      // Если из текущей вершины по текущему символу не было создано перехода
      if (curr->children.find(c) == curr->children.end()) {
        // Создаем переход
        curr->children[c] = new TreeNode(c);
        curr->children[c]->parent = curr;
        curr->children[c]->dbgStr += curr->dbgStr + c;
      }
```

```
// Спускаемся по дереву
     curr = curr->children[c];
   cout << "Вставляем строку: " << str << endl;
   printTrie();
   // Показатель терминальной вершины, значение которого равно порядковому номеру добавления
шаблона
   curr->numOfPattern = ++countPatterns;
 }
 // Функция для поиска подстроки в строке при помощи автомата
 vector<size_t> find(const char c) {
   static const TreeNode *curr = this; // Вершина, с которой необходимо начать следующий вызов
   cout << "Ищем '" << c << "' из: " << (curr->dbgStr.empty() ? "Корень" : curr->dbgStr) << endl; // Дебаг
   for (; curr != nullptr; curr = curr->suffixLink) {
     // Обходим потомков, если искомый символ среди потомков не найден, то
     // переходим по суффиксной ссылке для дальнейшего поиска
     for (auto child : curr->children)
       if (child.first == c) { // Если символ потомка равен искомому
         curr = child.second; // Значение текущей вершины переносим на этого потомка
         vector<size_t> found; // Вектор номеров найденных терм. вершин
         // ИНДИВИДУАЛИЗАЦИЯ
//
           if (curr->numOfPattern) { // Для пропуска пересечений, после нахождения терминальной
вершины
             found.push_back(curr->numOfPattern - 1); // Добавляем к найденным эту вершину
//
//
             curr = this; // И переходим в корень
//
         // НЕ ИНДИВИДУАЛИЗАЦИЯ
         // Обходим суффиксы, т.к. они тоже могут быть терминальными вершинами
         for (auto temp = curr; temp->suffixLink; temp = temp->suffixLink)
           if (temp->numOfPattern)
             found.push_back(temp->numOfPattern - 1);
         //
         cout << "Символ '" << c << "' найден!" << endl; // Дебаг
         return found;
       }
     if (curr->suffixLink) {
       cout << "Переходим по суффиксной ссылке: ";
       cout << (curr->suffixLink->dbgStr.empty()? "Корень" : curr->suffixLink->dbgStr) << endl;
     }
   cout << "Символ '" << c << "' не найден!" << endl; // Дебаг
   curr = this;
   return {};
 // Функция для построения недетерминированного автомата
 void makeAutomaton() {
   cout << "Строим автомат: " << endl;
   queue<TreeNode *> queue; // Очередь для обхода в ширину
   for (auto child : children) // Заполняем очередь потомками корня
     queue.push(child.second);
   while (!queue.empty()) {
     auto curr = queue.front(); // Обрабатываем верхушку очереди
```

```
// Для дебага
     cout << curr->dbgStr << ':' << endl;</pre>
     if (curr->parent && curr->parent->value)
        cout << "\tPoдитель: " << curr->parent->dbgStr << endl;
     else if (curr->parent)
       cout << "\tРодитель: Корень" << endl;
     if (!curr->children.empty())
       cout << "\tПотомок: ";
     //
      // Заполняем очередь потомками текущей верхушки
     for (auto child: curr->children) {
       cout << child.second->value << ' '; // Дебаг
       queue.push(child.second);
     }
      // Дебаг
     if (!curr->children.empty())
       cout << endl;
     queue.pop();
     auto p = curr->parent; // Ссылка на родителя обрабатываемой вершины
     char x = curr->value; // Значение обрабатываемой вершины
     if (p) p = p->suffixLink; // Если родитель существует, то переходим по суффиксной ссылке
     // Пока можно переходить по суффиксной ссылке или пока
     // не будет найден переход в символ обрабатываемой вершины
     while (p && p->children.find(x) == p->children.end())
       p = p->suffixLink; // Переходим по суффиксной ссылке
     // Суффиксная ссылка для текущей вершины равна корню, если не смогли найти переход
     // в дереве по символу текущей вершины, иначе равна найденной вершине
     curr->suffixLink = p ? p->children[x] : this;
     // Дебаг
     cout << "\tСуффиксная ссылка: " << (curr->suffixLink == this? "Корень" : curr->suffixLink->dbgStr) << endl
<< endl;
   }
    // Дебаг
   cout << endl;
    printTrie();
  ~TreeNode() { // Деструктор ноды
    for (auto child: children) delete child.second;
 }
 string dbgStr = ""; // Для отладки
 char value; // Значение ноды
 size_t numOfPattern = 0; // Номер введенного паттерна
 TreeNode *parent = nullptr; // Родитель ноды
 TreeNode *suffixLink = nullptr; // Суффиксная ссылка
 unordered_map <char, TreeNode*> children; // Потомок ноды
class Trie {
public:
 Trie() : root('\0') {} // Конструктор бора
 void insert(const string &str) { root.insert(str); }
 auto find(const char c) { return root.find(c); }
 void makeAutomaton() { root.makeAutomaton(); }
```

};

```
private:
  TreeNode root; // Корень бора
auto AhoCorasick(const string &text, const vector <string> &patterns)
  Trie bor;
  set <pair<size_t, size_t>> result;
  for (const auto &pattern: patterns) // Заполняем бор введенными паттернами
    bor.insert(pattern);
  bor.makeAutomaton(); // Из полученного бора создаем автомат (путем добавления суффиксных ссылок)
  for (\text{size\_t j} = 0; \text{j} < \text{text.size}(); \text{j++}) // Проходим циклом по строке, для каждого символа строки запускаем
    for (auto pos: bor.find(text[j])) // Проходим по всем найденным позициям, записываем в результат
      result.emplace(j - patterns[pos].size() + 2, pos + 1);
  return result;
}
int main()
{
  system("chcp 65001");
  string text;
  size_t n;
  cin >> text >> n;
  vector <string> patterns(n);
  for (size_t i = 0; i < n; i++)
    cin >> patterns[i];
  auto res = AhoCorasick(text, patterns);
  for (auto r : res)
    cout << r.first << ' ' << r.second << endl;</pre>
  return 0;
}
```

Приложение В

Код программы 2

```
#include <iostream>
#include <string>
#include <vector>
#include <queue>
#include <unordered_map>
using namespace std;
class TreeNode {
public:
  explicit TreeNode(char val): value(val) {} // Конструктор ноды
 // Отладочная функция для печати бора
 void printTrie() {
    cout << "Бор сейчас:" << endl;
    queue<TreeNode *> queue;
    queue.push(this);
    while (!queue.empty()) {
      auto curr = queue.front();
      if (!curr->value)
       cout << "Корень:" << endl;
      else
        cout << curr->dbgStr << ':' << endl;</pre>
      if (curr->suffixLink)
        cout << "\tCyффиксная ссылка: " << (curr->suffixLink == this? "Root" : curr->suffixLink->dbgStr) << endl;
      if (curr->parent && curr->parent->value)
        cout << "\tPoдитель: " << curr->parent->dbgStr << endl;
      else if (curr->parent)
        cout << "\tРодитель: Корень" << endl;
      if (!curr->children.empty()) cout << "\tПотомок: ";
      for (auto child: curr->children) {
        cout << child.second->value << ' ';</pre>
        queue.push(child.second);
      }
      queue.pop();
      cout << endl;
   }
   cout << endl;
 }
 // Вставка подстроки в бор
 void insert(const string &str, size_t pos, size_t size) {
   auto curr = this;
    for (char c : str) { // Идем по строке
      // Если из текущей вершины по текущему символу не было создано перехода
      if (curr->children.find(c) == curr->children.end()) {
        // Создаем переход
        curr->children[c] = new TreeNode(c);
        curr->children[c]->parent = curr;
        curr->children[c]->dbgStr += curr->dbgStr + c;
      // Спускаемся по дереву
```

```
curr = curr->children[c];
  }
  cout << "Вставляем строку: " << str << endl;
  printTrie();
  curr->substringEntries.emplace_back(pos, size);
}
vector <pair<size_t, size_t>> find(const char c)
  static const TreeNode *curr = this; // Вершина, с которой необходимо начать следующий вызов
  cout << "Ищем '" << c << "' из: " << (curr->dbgStr.empty() ? "Корень" : curr->dbgStr) << endl; // Дебаг
  for (; curr != nullptr; curr = curr->suffixLink) {
    // Обходим потомков, если искомый символ среди потомков не найден, то
    // переходим по суффиксной ссылке для дальнейшего поиска
    for (auto child : curr->children)
      if (child.first == c) { // Если символ потомка равен искомому
        curr = child.second; // Значение текущей вершины переносим на этого потомка
        // вектор пар, состоящих из начала безмасочной подстроки в маске и её длины
       vector <pair<size_t, size_t>> found;
       // Обходим суффиксы, т.к. они тоже могут быть терминальными вершинами
       for (auto temp = curr; temp->suffixLink; temp = temp->suffixLink)
          for (auto el : temp->substringEntries)
           found.push back(el):
       cout << "Символ '" << c << "' найден!" << endl; // Дебаг
       return found:
      }
    // Дебаг
    if (curr->suffixLink) {
      cout << "Переходим по суффиксной ссылке: ";
      cout << (curr->suffixLink->dbgStr.empty()? "Корень" : curr->suffixLink->dbgStr) << endl;
   }
  cout << "Символ '" << c << "' не найден!" << endl; // Дебаг
  curr = this:
  return {};
// Функция для построения недетерминированного автомата
void makeAutomaton() {
  cout << "Строим автомат: " << endl;
  queue<TreeNode *> queue; // Очередь для обхода в ширину
  for (auto child: children) // Заполняем очередь потомками корня
    queue.push(child.second);
  while (!queue.empty()) {
    auto curr = queue.front(); // Обрабатываем верхушку очереди
    // Для дебага
    cout << curr->dbgStr << ':' << endl;</pre>
    if (curr->parent && curr->parent->value)
      cout << "\tРодитель: " << curr->parent->dbgStr << endl;
    else if (curr->parent)
      cout << "\tРодитель: Корень" << endl;
    if (!curr->children.empty())
      cout << "\tПотомок: ";
```

```
//
      // Заполняем очередь потомками текущей верхушки
      for (auto child : curr->children) {
        cout << child.second->value << ' '; // Дебаг
        queue.push(child.second);
      }
      // Дебаг
      if (!curr->children.empty())
       cout << endl;
      queue.pop();
      auto p = curr->parent; // Ссылка на родителя обрабатываемой вершины
      char x = curr->value; // Значение обрабатываемой вершины
      if (p) p = p->suffixLink; // Если родитель существует, то переходим по суффиксной ссылке
      // Пока можно переходить по суффиксной ссылке или пока
      // не будет найден переход в символ обрабатываемой вершины
      while (p && p->children.find(x) == p->children.end())
        p = p->suffixLink; // Переходим по суффиксной ссылке
      // Суффиксная ссылка для текущей вершины равна корню, если не смогли найти переход
      // в дереве по символу текущей вершины, иначе равна найденной вершине
      curr->suffixLink = p ? p->children[x] : this;
      cout << "\tСуффиксная ссылка: " << (curr->suffixLink == this? "Корень" : curr->suffixLink->dbgStr) << endl
<< endl:
    }
    // Дебаг
    cout << endl;
    printTrie();
  ~TreeNode()
    for (auto child: children)
      delete child.second;
  }
private:
  string dbgStr = ""; // Для отладки
  char value; // Значение ноды
  TreeNode *parent = nullptr; // Родитель ноды
  TreeNode *suffixLink = nullptr; // Суффиксная ссылка
  unordered_map <char, TreeNode*> children; // Потомок ноды
  vector <pair<size_t, size_t>> substringEntries;
};
class Trie {
public:
  Trie(): root('\0') {}
  void insert(const string &str, size_t pos, size_t size)
    root.insert(str, pos, size);
  auto find(const char c)
    return root.find(c);
  void makeAutomaton()
```

```
{
    root.makeAutomaton();
private:
  TreeNode root;
auto AhoCorasick(const string &text, const string &mask, char joker) {
  Trie bor;
  vector <size_t> result;
  vector <size_t> midArr(text.size()); // Массив для хранения кол-ва попаданий безмасочных подстрок в
текст
  string pattern;
  size_t numSubstrs = 0; // Количество безмасочных подстрок
  for (size_t i = 0; i <= mask.size(); i++) { // Заполняем бор безмасочными подстроками маски
    char c = (i == mask.size()) ? joker : mask[i];
    if (c!= joker)
      pattern += c;
    else if (!pattern.empty()) {
      numSubstrs++;
      bor.insert(pattern, i - pattern.size(), pattern.size());
      pattern.clear();
   }
  }
  bor.makeAutomaton();
  for (size_t j = 0; j < text.size(); j++)
    for (auto pos : bor.find(text[j])) {
      // На найденной терминальной вершине вычисляем индекс начала маски в тексте
      int i = int(j) - int(pos.first) - int(pos.second) + 1;
      if (i \ge 0 \&\& i + mask.size() \le text.size())
        midArr[i]++; // Увеличиваем её значение на 1
    }
  for (size_t i = 0; i < midArr.size(); i++) {
    // Индекс, по которым промежуточный массив хранит количество
    // попаданий безмасочных подстрок в текст, есть индекс начала вхождения маски
    // в текст, при условии, что кол-во попаданий равно кол-ву подстрок б/м
    if (midArr[i] == numSubstrs) {
      result.push_back(i + 1);
      // ИНДИВИДУАЛИЗАЦИЯ
      // для пропуска пересечений, после найденного индекса, увеличиваем его на длину маски
      i += mask.size() - 1;
   }
  }
  return result;
}
int main()
  system("chcp 65001");
  string text, mask;
  char joker;
  cin >> text >> mask >> joker;
  for (auto ans : AhoCorasick(text, mask, joker))
    cout << ans << endl;</pre>
```

```
return 0;
}
```